

Auto ARS Research Tool

Auto ARS Research Tool est un utilitaire Python conçu pour automatiser la recherche et l'extraction d'arrêtés publiés dans les **Recueils des Actes Administratifs (RAA)** des préfectures régionales françaises.

Il télécharge et analyse les recueils à la recherche de mots-clés spécifiques, et extrait les arrêtés relatifs aux autorisations d'équipements en matériel lourd (EML), ainsi qu'aux bilans quantifiés / quantitatifs de l'offre de soins.

Ces derniers sont ensuite uploadés et répartis dans un SharePoint d'entreprise pour y être traités.

L'application est déployée sur une machine virtuelle Azure et automatisée via le planificateur de tâches Windows.

Arborescence

Emplacement du projet: C:\ProgramData\AutoARS

```
.
├─ env/                # environnement virtuel Python (venv)
├─ notebooks/         # Jupyter Notebook
│   └─ auto_ars_v1.5.ipynb # Dernière version du notebook
│   └─ archives        # Anciennes versions du notebook
├─ auto_ars.log        # Journal d'exécution généré par run_auto_ars.bat
├─ auto_ars_v1.5.py    # script principal : main() -> search_and_extract()
├─ journal.log         # Journal d'exécution généré par auto_ars_v1.5.py
├─ readme.md          # documentation d'installation et d'usage
├─ requirements.txt    # liste des dépendances (pip freeze)
└─ run_auto_ars.bat    # batch pour planifier : active le venv & lance le script
```

Élément	Type	Description
env/	Dossier	Environnement virtuel Python (venv)
notebooks/	Dossier	Versions Jupyter du script pour développement interactif
auto_ars.log	Fichier	Logs d'exécution (contient tous les logs générés par le fichier batch)
auto_ars_v1.5.py	Script	main()
journal.log	Fichier	Logs d'exécution (dernier log généré par le script)
readme.md	Documentation	Mode d'emploi, prérequis, installation et exemples d'utilisation
requirements.txt	Fichier	versions des bibliothèques utilisées (sortie de pip freeze)
run_auto_ars.bat	Batch file	

Sommaire

- [Guide d'installation](#)
 - [I. Prérequis](#)
 - [1. Python 3.12.x](#)
 - [2. Environnement Virtuel](#)
 - [3. Librairies](#)
 - [4. Outils de développement](#)
 - [II. Ajout d'un nouvel utilisateur](#)
 - [1. GAMA - Demande de création de compte](#)
 - [2. Ajout d'un nouveau compte](#)
 - [3. Connection à la Virtual Machine Azure](#)
 - [4. SharePoint & Authentification SAML](#)
 - [III. Paramètres & Configuration](#)
 - [1. Compte Service](#)
 - [2. SharePoint](#)
 - [3. Tâche Planifiée](#)
- [Utilisation](#)
 - [I. Ligne de commande & Task Scheduler](#)
 - [II. Jupyter Notebook](#)
 - [III. Paramètres](#)
 - [1. Régions, Mois & Année](#)
 - [2. SharePoint & Mots Clés](#)
 - [IV. Exemple de sortie](#)
- [Maintenance](#)
 - [I. Mettre à jour la fonction get_url\(\)](#)
 - [1. Structure de la fonction get_url\(\)](#)
 - [2. Cas pratiques](#)
 - [1. Corse](#)
 - [2. Occitanie](#)
 - [3. Martinique](#)
 - [II. Mettre à jour la fonction get_titles_and_links\(\)](#)
 - [III. Limitations & erreurs](#)

Guide d'installation

I. Prérequis

Sur la virtual machine (Windows Server 2019) dédiée à **AutoARS** qui vous est fournie, Python 3.12.x, pip et l'environnement virtuel sont installés et configurés.

Les étapes décrites plus bas ne s'appliqueront qu'à une nouvelle installation (nouvelle VM ou poste local), et sous **Windows** uniquement.

1. Python 3.12.x

L'utilitaire a été développé sous Python v3.12.

Pour installer Python, suivez l'une des deux méthodes ci-dessous :

1. **via le site Python.org** (*non compatible avec la virtual machine*)

- rendez vous sur <https://www.python.org/downloads/release/python-31210>
- sous "**Files**" téléchargez et exécutez le fichier **Windows installer (64-bit)** (.exe).
- cochez **Add python.exe to PATH**, puis **Install Now**

2. **via Chocolatey** (*recommandée*)

Ouvrez une fenêtre PowerShell **en tant qu'administrateur** et exécutez :

```
Set-ExecutionPolicy Bypass -Scope Process -Force
[Net.ServicePointManager]::SecurityProtocol = [Net.SecurityProtocolType]::Tls12
iex ((New-Object System.Net.WebClient).DownloadString('https://community.chocolatey.org/install.ps1'))
choco install python --version=3.12.10 -y
```

Pour vérifier l'installation :

```
python --version
pip --version
```

Vous devriez obtenir :

```
Python 3.12.10
pip 25.y.z from ... (python 3.12)
```

2. Environnement Virtuel

Le programme s'exécute sous un environnement virtuel.

L'environnement virtuel (dossier **env**) contient les librairies, pour le créer et l'activer :

- Placez-vous à la racine de votre projet (ici **C:\ProgramData\AutoARS**) :

```
cd "C:\ProgramData\AutoARS"
```

- Puis :

```
python -m venv env
.\env\Scripts\activate
```

Vous saurez que l'environnement est activé si le nom (env) apparaît au début de votre invite de commande.

3. Librairies

Pour installer les librairies :

- Assurez-vous que le fichier `requirements.txt` est dans le dossier racine du projet.
- Dans PowerShell, assurez vous d'être à la racine du projet et d'avoir votre environnement virtuel activé.

Si c'est le cas, votre invite de commande devrait ressemblera à cela :

```
(env) PS C:\ProgramData\AutoARS>
```

sinon,

```
cd "C:\ProgramData\AutoARS"  
.\env\Scripts\activate
```

- Pour installer les librairies :

```
pip install -r requirements.txt
```

Liste des principales librairies et leurs usages :

Package	Usage
requests	Requêtes HTTP
beautifulsoup4	Parsing HTML
selenium	Automatisation de navigateur (authentification SAML)
PyMuPDF (<i>fitz</i>)	Traitement de PDF
pandas	Mise en forme & manipulation de données
babel	Formatage des dates
Office365-REST-Python-Client	Upload sur SharePoint
logging	Journal des événements
io.BytesIO	Gestion des flux binaires
re	Regex -> Expressions régulières pour analyse de texte
time	Gestion des délais et temporisations
datetime	Calcul & manipulation des dates

4. Outils de développement

Pour éditer, exécuter et déboguer efficacement votre notebook Jupyter ou le script Python, il est recommandé d'utiliser un éditeur de code ou un IDE (Environnement de Développement Intégré).

Visual Studio Code est installé sur votre VM pour tous les utilisateurs, dans le cas contraire :

- rendez-vous sur <https://code.visualstudio.com/download>
- téléchargez et exécutez le fichier **User Installer** *x64 Arm64* pour l'installer sur votre compte utilisateur ou téléchargez et exécutez le fichier **System Installer** *x64 Arm64* pour une installation système (tout utilisateur)
- installez les extensions **Python + Jupyter**
(à l'ouverture du notebook ou du script, vscode vous proposera automatiquement les extensions associées, onglet *Extensions* côté gauche de votre écran ou *Ctrl+Maj+X*)

VS Code est également disponible dans les applications de votre portail d'entreprise.

II. Ajout d'un nouvel utilisateur

Pour vous connecter à la virtual machine & utiliser l'outil AutoARS, vous aurez besoin :

- d'un compte de type **GAMA identity + Admin-Account managed by PAM (AD005)**
- d'intégrer vos identifiants Siemens Healthineers aux variables d'environnement de votre compte utilisateur (seul l'utilisateur en question peut effectuer cette opération)

1. GAMA - Demande de création de compte

Pour faire une demande de création de compte de type **GAMA identity + Admin-Account managed by PAM (AD005)**, rendez-vous sur : <https://gama.healthcare.siemens.com/webCenterGAMA/auth/pages/dashboard/dashboard.jsf>

- Dans le menu de gauche, cliquez sur **New Functional User (FUN)** puis cochez la case **GAMA identity + Admin-Account managed by PAM (AD005)**, puis **Next**
- Remplissez les champs et validez

Vous recevrez sous 48h un mail de confirmation contenant un mot de passe provisoire et un lien vous permettant d'initialiser votre nouveau compte.

Demandez ensuite à un **administrateur** de la VM d'ajouter votre compte aux groupes locaux.

2. Ajout d'un nouveau compte (*nécessite un compte admin déjà intégré*)

Pour ajouter un nouveau compte aux groupes locaux :

1. ouvrez **Computer Management** (`compmgmt.msc`)
2. dans l'arborescence de gauche :

```
System Tools
└─ Local Users and Groups
    └─ Groups
```

3. double-cliquez sur le groupe **Administrators**, puis **Add...**
4. dans le champs **Locations...**, vérifiez que vous êtes bien sur **ad005.onehc.net**
5. dans **Enter the object names to select** tapez le nom de votre compte (*votre GID - ex: k0055kuv*), puis **Check Names**, cliquez sur votre compte puis validez

3. Connection à la Virtual Machine Azure

Pour vous connecter à la machine virtuelle :

1. Ouvrez **Connexion Bureau à Distance**
2. Dans le champs **Ordinateur** rentrez l'adresse du serveur : **10.83.248.190**
3. Connectez vous avec votre nouvel identifiant : **AD005\<Windows_account>** (ex : **AD005\Z0055V7F-A01**)

Vous serez alors invité à rentrer votre mot de passe de session à distance.

Pour obtenir ce dernier :

1. Rendez-vous sur <https://cyberark.siemens-healthineers.com/PasswordVault/v10>
2. Dans la **Vue des comptes**, identifiez le nom du compte précédemment créé sur **GAMA**
3. Cliquez dessus puis **Copier**.

Collez votre mot de passe provisoire et validez.

Une fois connecté, activer l'affichage des dossiers cachés pour accéder à certains répertoires comme "ProgramData" Dans le menu de l'explorateur de fichier : **View** -> cochez **File name extensions & Hidden items**

4. SharePoint & Authentification SAML

Pour utiliser **AutoARS** (hors tâche planifiée), il est nécessaire d'entrer vos identifiants Siemens Healthineers dans les variables d'environnement de votre session à distance (*ou locale*).

Ces données seront stockées dans le système et accessibles uniquement via votre compte utilisateur.

Elles permettront à l'application de s'identifier auprès du SharePoint **MSC BD - Autorisations ARS** lors de l'extraction des arrêtés, sous conditions d'avoir les droits nécessaires.

Bien que le compte service **z0055kuv** ai ses propres identifiants, il n'est pas possible d'ouvrir une session à distance avec ce dernier. Toute utilisation de l'application via un compte utilisateur doit être en mesure de s'identifier via les identifiants de ce dernier.

Dans une fenêtre PowerShell :

```
[Environment]::SetEnvironmentVariable("SP_USERNAME", "<votre_nom_utilisateur>", "User")
[Environment]::SetEnvironmentVariable("SP_PASSWORD", "<votre_mot_de_passe>", "User")
```

Ou via l'explorateur de fichiers :

- Ouvrez **File Explorer**, clic droit sur **This PC** -> **Properties**, puis **Advanced system setting** dans l'onglet de gauche
- Cliquez sur **Environment Variables...**, puis sous **User variables for <account_name>** cliquez sur **New...** et ajoutez :

Variable	Value
SP_USERNAME	<votre_nom_utilisateur>
SP_PASSWORD	<mot_de_passe_du_service>

III. Paramètres & Configuration

1. Compte Service

Le compte **z0055kuv** est le compte de service qui exécute la tâche planifiée **AutoARS**.

C'est un compte de type **GAMA identity + SCD + Windows-Account (AD005) + Mailbox**.

```
- id : autoars.func@siemens-healthineers.com
- mdp : Receuil_Decrets_2025
```

1. Création d'un Functional User (FUN)

- Rendez vous sur GAMA :
<https://gama.healthcare.siemens.com/webCenterGAMA/auth/pages/dashboard/dashboard.jsf>
- Dans le menu de gauche, cliquez sur **New Functional User (FUN)**, cochez **GAMA identity + SCD + Windows-Account (AD005) + Mailbox**, puis **Next**
- Renseignez les champs et validez

Une fois votre compte service créé vous pourrez l'ajouter à votre Virtual Machine.

2. Ajouter le compte service aux groupes locaux

- Ouvrez **Computer Management** (`compmgmt.msc`)
- Dans l'arborescence de gauche :

```
System Tools
├─ Local Users and Groups
│   └─ Groups
```

- Double-cliquez sur le groupe **Users** -> **Add...**
- **Locations...**, sélectionnez **ad005.onehc.net**
- Entrez le nom de l'objet (ex: *k0055kuv*), **Check Names**, puis **OK**

3. Configuration du compte service

- **Attribuer les droits "Log on as a batch job"** (pour le planificateur de tâches) :
 - 1. Ouvrez **Local Security Policy** (*secpol.msc*)
 - 2. Naviguez jusqu'à :

```
Security Settings
└─ Local Policies
    └─ User Rights Assignment
        └─ Log on as a batch job
```

- 3. Double-cliquez sur **Log on as a batch job** -> **Add User or group...**
- 4. **Locations...** -> **ad005.onehc.net**
- 5. Tapez le nom de votre compte (ex : *z0055kuv*), **Check Names**, **OK**, **Apply**
- 6. Ouvrez une fenêtre PowerShell en tant qu'administrateur, exécutez :

```
gpupdate /force
```

- **Configurer les permissions NTFS sur le dossier de travail :**

Via l'explorateur :

- 1. Dans l'Explorateur, faites un clic droit sur **C:\ProgramData\AutoARS**-> **Properties** > **Security**
- 2. Cliquez sur **Edit...**, **Add...**, tapez le nom de votre compte (ex : *z0055kuv*), **Check Names**, **OK**
- 3. Donnez au moins les droits pour **Read & execute**, **List folder contents**, **Write**, **Modify**
- 4. Cochez **Replace all child object permissions...** pour propager aux sous-dossiers

Ou via une ligne de commande en mode **Admin** :

```
icacls "C:\ProgramData\AutoARS" /grant "AD005\z0055kuv:(OI)(CI)M" /T
```

Remplacez *z0055kuv* par le nom de votre compte

- **Définir les variables d'environnement (Machine-scope)** (authentification SAML pour l'accès au Sharepoint) :

Dans une fenêtre PowerShell, ouverte en tant qu'administrateur :

```
[Environment]::SetEnvironmentVariable("SP_USERNAME", "<votre_nom_utilisateur>", "Machine")
[Environment]::SetEnvironmentVariable("SP_PASSWORD", "<votre_mot_de_passe>", "Machine")
```

Exemple :

```
[Environment]::SetEnvironmentVariable("SP_USERNAME", "autoars.func@siemens-healthineers.com",
"Machine")
[Environment]::SetEnvironmentVariable("SP_PASSWORD", "<password>", "Machine")
```

Ou via l'explorateur de fichiers :

- Ouvrez **File Explorer**, clic droit sur **This PC** -> **Properties**, puis **Advanced system settings** dans l'onglet de gauche
- Cliquez sur **Environment Variables...**, puis sous **System variables** cliquez sur **New...** et ajoutez :

Variable	Value
SP_USERNAME	<votre_nom_utilisateur>
SP_PASSWORD	<mot_de_passe_du_service>

2. SharePoint

Lors de son exécution, l'utilitaire AutoARS retourne les arrêtés extraits, la synthèse de ses recherches, et un journal d'événements vers le SharePoint [MSCBD–AutorisationsARS](#).

Quelque soit le compte utilisé (admin ou service) ce dernier doit :

1. Avoir défini ses identifiants (login et password) en variables d'environnement dans le système utilisé (ordinateur local ou virtual machine)
 - avec un scope "User" s'il s'agit d'un compte admin
 - avec un scope "Machine" s'il s'agit d'un compte service
2. Avoir obtenu ses accès en lecture / écriture au niveau du SharePoint

Disposer du rôle **Owner** n'implique pas forcément le droit **Contribute/Edit** via l'API REST.

Le compte doit faire partie d'un groupe auquel on a explicitement confié le rôle **Contribute** (ou supérieur) sur la librairie **Shared Documents**.

3. Tâche Planifiée

La tâche planifiée **AutoARS** permet d'automatiser l'exécution du script **auto_ars_v1.5.py**.

Par défaut c'est le compte service **z0055kuv** qui exécute la tâche.

Pour configurer la tâche planifiée:

1. Ouvrez **Task Scheduler**, onglet de gauche **Task Scheduler Library**
2. Editez ou créez la tâche **AutoARS**:
 - General -> When running the task, use the following user account : **z0055kuv**
 - cochez **Run whether user is logged on or not** et **Run with highest privileges**
3. **Actions** -> **New...** ou **Edit...**
 - **Action:** **Start a program**
 - **Settings**
 - **Programm/script:** **C:\Windows\System32\cmd.exe**
 - **Add arguments:** **/c "cd /d C:\ProgramData\AutoARS && run_auto_ars.bat"**
 - **Start in :** **C:\ProgramData\AutoARS**
4. **Triggers** -> configurez votre planning

A la validation, Windows vous demandera le mot de passe du compte service

Utilisation

I. Ligne de Commande & Task Scheduler

- En ligne de commande :

```
# Se déplacer à la racine du projet
cd "C:\ProgramData\AutoARS"
# Activez l'env
.\env\Scripts\activate
# Lancez le script
python auto_ars_v1.5.py
```

- Via le planificateur de tâches :

Ouvrir **Task Scheduler**, cliquer sur la tâche **AutoARS** -> onglet droit **Actions** -> **Selected Item** -> **Run**

En ligne de commande ou via le planificateur de tâches, l'application s'exécute avec les paramètres par défaut, soit :

```
regions = all_regions                # toutes les régions -> list(str)
months = previous_month              # mois précédent le mois courant -> list(str)
year = str(now.year if now.month > 1 else now.year - 1) # année courante ou précédente si le mois est
janvier -> str
```

Pour modifier les paramètres, privilégiez l'utilisation du notebook via un Jupyter Notebook.

II. Jupyter Notebook

Dans VS Code :

1. Ouvrez le dossier du projet (**File > Open folder**) -> **c:\ProgramData\AutoARS**
2. Ouvrez le notebook (**File > Open file**) -> **c:\ProgramData\AutoARS\notebooks\auto_ars_v1.5.ipynb**
3. Sélectionnez l'interpréteur Python (**Ctrl+Shift+P** -> **Python: Select Interpreter** -> **env/Scripts/python.exe**)
4. Suivez les instructions directement dans le notebook.

III. Paramètres

1. Régions, Mois & Année

1. Configurer les paramètres de recherche

Spécifier :

- la ou les régions cibles (*sélectionner 1 à 17 régions*)
- le ou les mois (*sélectionner 1 à 12 mois*)
- l'année souhaitée (*sélectionner 1 année*)

Exemple :

```
regions = ['ile-de-france', 'bretagne']
months = ['septembre', 'octobre']
year = '2024'
```

Ce paramétrage effectue une recherche sur les régions *Ile-de-France* et *Bretagne*, pour les mois de *septembre* et *octobre* 2024.

Les variables **regions** et **mois** sont définies sous forme de '*chaînes de caractères*'.
Elles doivent impérativement être incluses dans une *[liste]*, les arguments étant séparés par une virgule.
Sans accent et sans majuscule.

Détails des options :

Les régions compatibles se composent des 12 régions métropolitaines, de la Corse et des DROM-TOM.

- Régions compatibles :

'auvergne-rhone-alpes', 'bourgogne-franche-comte', 'bretagne', 'centre-val-de-loire', 'corse', 'grand-est', 'guadeloupe', 'guyane', 'hauts-de-france', 'ile-de-france', 'martinique', 'normandie', 'nouvelle-aquitaine', 'occitanie', 'pays-de-la-loire', 'provence-alpes-cote-dazur', 'reunion'

Elles doivent être spécifiées comme telles, en respectant la casse et encadrées par des simples ou doubles quotes.

- Mois compatibles :

'janvier', 'fevrier', 'mars', 'avril', 'mai', 'juin', 'juillet', 'aout', 'septembre', 'octobre', 'novembre', 'decembre'

Ils doivent être spécifiés comme tels, en respectant la casse et encadrés par des simples ou doubles quotes.

- Année :
 - Doit être une chaîne de caractères, par exemple : '2024'.
 - Seules les années disponibles dans les archives (de 2016 à aujourd'hui) sont compatibles.

Assurez vous de choisir une période disponible.

Vous pouvez également utiliser les paramètres par défaut :

```
regions = all_regions          # toutes les régions -> list(str)
months = previous_month        # mois précédent le mois courant -> list(str)
year = str(now.year if now.month > 1 else now.year - 1) # année courante ou précédente si le mois est
janvier -> str
```

Ou utiliser d'autres paramètres pré-définis :

```
regions = all_regions  # toutes les régions -> list(str)
months = current_month # mois courant -> list(str)
year = current_year    # année courante -> str
```

Les variables `all_regions`, `previous_month` et `current_month` sont des listes de chaînes de caractères

2. Lancez la fonction principale :

Une fois les paramètres définis, exécutez la fonction:

```
search_and_extract(regions, months, year)
```

3. Consulter les résultats

Les résultats incluent :

- Un rapport détaillé des recherches (ex : `ARS_report - 2025.07.xlsx`)
- Les arrêtés pertinents seront transféré dans un dossier associé (ex : `ARS Ile-de-France - 2025.07`)
- Un journal d'événements (ex : `journal_20250724.log`)

Pour les consulter : [MSCBD–Autorisations ARS](#)

2. SharePoint & Mots Clés

SharePoint

L'adresse du SharePoint est définie comme telle :

```
sharepoint = (  
    "https://healthineers.sharepoint.com"  
    "/teams"  
    "/MSCBusinessDevelopment-AutorisationsARS"  
)  
server_relative_root = (  
    "/teams"  
    "/MSCBusinessDevelopment-AutorisationsARS"  
    "/Shared Documents"  
    "/Autorisations ARS"  
    "/Results"  
)
```

En cas de changement d'adresse, modifiez ces variables.

Mots Clés

Les mots clés sont définis comme tels :

```
keywords = [  
    r'Bilan(?:s)? Quantitatif(?:s)?',  
    r'Bilan(?:s)? Quantifié(?:s)?',  
    r'\bTEP\b',  
    r'\bIRM\b',  
    r'Résonance Magnétique',  
    r'Scanographe',  
    r'Scanner',  
    r'Tomographe',  
    r'Scintillation',  
    r'Gamma',  
    r'Radiologie',  
    r'imagerie\s{1,2}en\s{1,2}coupes'  
]
```

Ils sont ensuite compilés dans la fonction :

```
def compile_keywords(keywords):  
    return [re.compile(r'\b' + keyword + r'\b', re.IGNORECASE) for keyword in keywords]
```

Pour ajouter / modifier, ou supprimer un ou des mots clés, modifiez la variable `keywords`

IV. Exemple de sortie

Après avoir exécuté la recherche, l'outil produit un rapport indiquant :

- L'index, la région, le nom des fichiers analysés
- Les liens des documents source
- L'état de téléchargement des fichiers PDF
(True ou False -> False indiquant une erreur lors du téléchargement du fichier)
- Les mots-clés trouvés et les numéros de pages extraites.

Index	Region	File Name	Link	PDF Loaded	Keywords Found
0	Auvergne-Rhône-Alpes	RAA régional spécial du 30 juin 2025	https://www.prefectures-regions.gouv.fr/auvergne-rhone-alpes/irecontenu/telechargement/129001/950492/file/20250630_recueil-84-2025-178-recueil-des-actes-administratifs-special.pdf	True	radiologie: Pages 99 to 100
...	...	...	...	...	...
352	Nouvelle-Aquitaine	recueil-r75-2025-116-recueil-des-actes-administratifs	https://www.prefectures-regions.gouv.fr/nouvelle-aquitaine/irecontenu/telechargement/128603/947969/file/recueil-r75-2025-116-recueil-des-actes-administratifs.pdf	True	IRM, résonance magnétique: Pages 12 to 15
...	...	...	...	...	...
429	Provence-Alpes-Côte d'Azur	Recueil-r93-2025-113_6 juin 2025	https://www.prefectures-regions.gouv.fr/provence-alpes-cote-dazur/irecontenu/telechargement/128293/945975/file/Recueil-r93-2025-113_6 juin 2025.pdf	True	TEP: Pages 107 to 113

 Maintenance

I. Mettre à jour la fonction get_url()

Pour accéder à la fonction get_url(), ouvrez le script `auto_ars_v1.5.py`, onglet gauche **Explorateur** (Ctrl+Maj+E), ouvrez le bloc **Structure**, puis faites défiler jusqu'à la fonction `get_url`.

Dans un notebook, faites défiler la 1ère cellule de code ou (Ctrl+F) -> `get_url` (1ère itération).

1. Structure de la fonction get_url()

La fonction get_url() a pour objectif de fournir l'adresse des pages web à scraper en fonction des paramètres `region`, `month`, et `year`. Pour ce faire, nous définissons au cas par cas des structures d'urls qui vérifient ces paramètres pour les cas passés et présents.

En raison de la variabilité de ces dernières, il est parfois nécessaire de modifier ces structures et d'ajouter un nouveau cas.

```
# schéma de la fonction

# On indente pour définir le bloc d'instructions associé à chaque cas conditionnel

def get_url(region, month, year): # définition <nom_fonction>(paramètres)

    # on indente après une déclaration de fonction

    match region: # on regarde la valeur de la variable region

        # on indente et on définit les différents cas

        case 'auvergne-rhone-alpes': # cas region = 'auvergne-rhone-alpes'

            # on indente et on déclare la variable
            url = '<url_auvergne-rhone-alpes>' # alors valeur de l'url

        # case 'corse' au même niveau d'indentation que case 'auvergne-rhone-alpes'
        case 'corse':

            # on indente et on définit le bloc d'instruction

            url_corse = '<url_corse>'

            url_corse_sud = '<url_corse_sud>'

            if int(year) >= 2025: # si l'année est supérieure ou égale à 2025

                # on indente et on définit le bloc d'instruction associé à if int(year) >= 2025

                if month in ['janvier', ...]: # si le mois est inclus dans la liste ['janvier', ...]
                    url_haute_corse = '<url_conditionnelle_haute_corse_n°1>'

                elif month in ['avril', ...]: # sinon si le mois est inclus dans la liste ['avril', ...]
                    url_haute_corse = '<url_conditionnelle_haute_corse_n°2>'

                else: # sinon (tous les autres mois)
                    url_haute_corse = '<url_conditionnelle_haute_corse_n°3>'

            else: # sinon (si l'année n'est pas supérieure ou égale à 2025)

                if month in ['avril', ...]:
                    url_haute_corse = '<url_conditionnelle_haute_corse_n°4>'

                else:
                    url_haute_corse = '<url_conditionnelle_haute_corse_n°5>'

            urls = [url_corse, url_corse_sud, url_haute_corse]

    return url if url else urls
```

La fonction get_url() renvoie une ou des urls sous forme de chaînes de caractères
Les urls renvoyées sont conditionnelles et fonctions des paramètres : region, month, year

Les urls prennent la forme suivante :

```
root = 'https://www.prefectures-regions.gouv.fr' # racine de l'url pour toutes les régions de France
Métropolitaine (hors Corse)

case 'auvergne-rhone-alpes':

    url = (
        f'{root}/{region}' # on utilise une f-string dès qu'une chaîne de caractères comprend une ou
plusieurs variables
        '/Documents-publications'
        '/Recueil-regional-des-actes-administratifs-RAA'
    )

# l'url est équivalente à:

url = f'{root}/{region}/Documents-publications/Recueil-regional-des-actes-administratifs-RAA'

# get_url('auvergne-rhone-alpes', 'juillet', '2025') renvoie la chaîne de caractères:

'https://www.prefectures-regions.gouv.fr/auvergne-rhone-alpes/Documents-publications/Recueil-regional-
des-actes-administratifs-RAA'
```

L'url de l'Auvergne-Rhône-Alpes n'est conditionnée que par sa région

```

case 'corse':

    url_corse = (
        'https://www.corse-du-sud.gouv.fr'
        '/Publications'
        '/Recueil-des-actes-administratifs'
        '/Recueil-des-actes-administratifs-de-la-Region-Corse'
        f'/Recueil-des-actes-administratifs-de-la-Region-Corse-pour-1-annee-{year}'
    )

    url_corse_sud = (
        'https://www.corse-du-sud.gouv.fr'
        '/Publications'
        '/Recueil-des-actes-administratifs'
        '/Recueil-des-actes-administratifs-de-la-prefecture-de-la-Corse-du-Sud'
        f'/Recueils-des-actes-administratifs-de-l-annee-{year}'
    )

    if int(year) >= 2025:

        if month in ['janvier', 'mai', 'juin', 'juillet', 'septembre', 'novembre', 'decembre']:

            url_haute_corse = (
                'https://www.haute-corse.gouv.fr'
                '/Publications'
                '/Publications-administratives-et-legales'
                '/Recueils-des-actes-administratifs'
                f'/Recueils-des-actes-administratifs-{year}'
                f'/RAA-du-mois-de-{month}-{year}'
            )

# les urls sont équivalentes à:

url_corse = f'https://www.corse-du-sud.gouv.fr/Publications/Recueil-des-actes-administratifs/Recueil-des-actes-administratifs-de-la-Region-Corse/Recueil-des-actes-administratifs-de-la-Region-Corse-pour-1-annee-{year}'

url_corse_sud = f'https://www.corse-du-sud.gouv.fr/Publications/Recueil-des-actes-administratifs/Recueil-des-actes-administratifs-de-la-prefecture-de-la-Corse-du-Sud/Recueils-des-actes-administratifs-de-l-annee-{year}'

url_haute_corse = f'https://www.haute-corse.gouv.fr/Publications/Publications-administratives-et-legales/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-{year}/RAA-du-mois-de-{month}-{year}'

# get_url('corse', 'juillet', '2025') renvoie une liste de chaines de caractères:

['https://www.corse-du-sud.gouv.fr/Publications/Recueil-des-actes-administratifs/Recueil-des-actes-administratifs-de-la-Region-Corse/Recueil-des-actes-administratifs-de-la-Region-Corse-pour-1-annee-2025',
 'https://www.corse-du-sud.gouv.fr/Publications/Recueil-des-actes-administratifs/Recueil-des-actes-administratifs-de-la-prefecture-de-la-Corse-du-Sud/Recueils-des-actes-administratifs-de-l-annee-2025',
 'https://www.haute-corse.gouv.fr/Publications/Publications-administratives-et-legales/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-2025/RAA-du-mois-de-juillet-2025']

```

Les urls corses sont conditionnées par la région, le mois, et l'année

2. Cas Pratiques

1. Corse - juin & juillet 2025

On s'intéresse ici uniquement à la partie `url_haute_corse` pour l'année 2025 ou ultérieure.

```
case 'corse': # cas region = 'corse'

    if int(year) >= 2025: # si l'integer année est supérieur ou égal à 2025

        if month in ['janvier', 'mai']: # si la variable mois est compris dans la liste ['janvier', 'mai']

            # alors valeur de la variable url_haute_corse
            url_haute_corse = (
                'https://www.haute-corse.gouv.fr'
                '/Publications'
                '/Publications-administratives-et-legales'
                '/Recueils-des-actes-administratifs'
                f'/Recueils-des-actes-administratifs-{year}'
                f'/RAA-du-mois-de-{month}-{year}'
            )

        elif month in ['avril', 'aout', 'octobre']: # sinon si le mois est compris dans la liste ['avril',
            'aout', 'octobre']

            # alors valeur de la variable url_haute_corse
            url_haute_corse = (
                'https://www.haute-corse.gouv.fr'
                '/Publications'
                '/Publications-administratives-et-legales'
                '/Recueils-des-actes-administratifs'
                f'/Recueils-des-actes-administratifs-{year}'
                f'/RAA-du-mois-d-{month}-{year}'
            )

        else: # sinon (tous les autres cas, dont juin et juillet)

            # alors valeur de la variable url_haute_corse
            url_haute_corse = (
                'https://www.haute-corse.gouv.fr'
                '/Publications'
                '/Publications-administratives-et-legales'
                '/Recueils-des-actes-administratifs'
                f'/Recueils-des-actes-administratifs-{year}'
                f'/RAA-du-mois-{month}-{year}'
            )
```

Les adresses renvoyées par la fonction `get_url('corse', 'juin', '2025')` et `get_url('corse', 'juillet', '2025')` renvoient une erreur 404 :

```
get_url('corse', 'juin', '2025')[2] # on choisit ici de ne renvoyer que le 3ème élément de la liste urls
(index 2 -> [2])
```

'https://www.haute-corse.gouv.fr/Publications/Publications-administratives-et-legales/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-2025/RAA-du-mois-juin-2025'

```
get_url('corse', 'juillet', '2025')[2]
```

'https://www.haute-corse.gouv.fr/Publications/Publications-administratives-et-legales/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-2025/RAA-du-mois-juillet-2025'

Pour récupérer l'adresse correcte, rendez-vous sur : <https://www.prefectures-regions.gouv.fr/>

- Sur la carte interactive, cliquer sur **Corse**, onglet droit **ACCES RAPIDES -> Recueil des actes administratifs -> Recueils des Actes Administratifs**
- La page suivante vous proposera ces 3 liens :
 - [Les recueils de la région Corse](#)
 - [Les recueils du département de la Corse du Sud](#)
 - [Les recueils du département de la Haute-Corse](#)
- On souhaite récupérer l'adresse correcte pour la Haute-Corse, cliquez sur le 3ème lien puis **Recueils des actes administratifs 2025**
- Faites défiler puis cliquez sur **RAA du mois de juin 2025**
- Dans le champs **adresse** de votre navigateur , copier l'adresse et coller là dans un éditeur de texte pour la comparer avec l'adresse renvoyée par la fonction

On obtient :

```
# url_haute_corse_incorrecte
'https://www.haute-corse.gouv.fr/Publications/Publications-administratives-et-legales/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-2025/RAA-du-mois-juin-2025'

# url_haute_corse_correcte
'https://www.haute-corse.gouv.fr/Publications/Publications-administratives-et-legales/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-2025/RAA-du-mois-de-juin-2025'
```

En répétant l'opération pour le mois de juillet 2025, on obtient :

```
# url_haute_corse_incorrecte
'https://www.haute-corse.gouv.fr/Publications/Publications-administratives-et-legales/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-2025/RAA-du-mois-juillet-2025'

# url_haute_corse_correcte
'https://www.haute-corse.gouv.fr/Publications/Publications-administratives-et-legales/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-2025/RAA-du-mois-de-juillet-2025'
```

Dans cet exemple, l'erreur se situe à la fin de l'adresse.

L'adresse correcte se termine par **RAA-du-mois-de-juillet-2025** et non par **RAA-du-mois-juillet-2025**

Corriger l'url renvoyée par `get_url()` :

- L'adresse correcte pour le mois de juillet nous est donnée par :

```
'https://www.haute-corse.gouv.fr/Publications/Publications-administratives-et-legales/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-2025/RAA-du-mois-de-juillet-2025'
```

- Mettre en forme et décomposer la variable `url_haute_corse`, remplacer les valeurs `juillet` et `2025` par leurs variables respectives :

```
url_haute_corse = 'https://www.haute-corse.gouv.fr/Publications/Publications-administratives-et-
legales/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-2025/RAA-du-mois-de-juillet-
2025'

# est équivalent à :

url_haute_corse = (
    'https://www.haute-corse.gouv.fr'
    '/Publications'
    '/Publications-administratives-et-legales'
    '/Recueils-des-actes-administratifs'
    '/Recueils-des-actes-administratifs-2025'
    '/RAA-du-mois-de-juillet-2025'
)

# remplacez les valeurs juillet & 2025 par leurs variables associées, et intégrez les dans une f-string
# ex :
# '/Recueils-des-actes-administratifs-2025' -> f'/Recueils-des-actes-administratifs-{year}'
# et '/RAA-du-mois-de-juillet-2025' -> f'/RAA-du-mois-de-{month}-{year}'
# (intégrer une chaîne de caractères dans une f-string n'est obligatoire que si cette dernière contient
une ou plusieurs variables)

# vous obtenez pour juin et juillet, la structure suivante :

url_haute_corse = (
    'https://www.haute-corse.gouv.fr'
    '/Publications'
    '/Publications-administratives-et-legales'
    '/Recueils-des-actes-administratifs'
    f'/Recueils-des-actes-administratifs-{year}'
    f'/RAA-du-mois-de-{month}-{year}'
)
```

La structure d'url obtenue est déjà définie dans la fonction `get_url()` pour le cas 'corse' dans la clause `int(year) >= 2025` et la sous clause `if month in ['janvier', 'mai']`.

Pour corriger la fonction, il nous suffit d'intégrer les mois de juin et juillet dans cette dernière :

Par extension, on peut également supposer que depuis mai 2025, tous les mois commençant par une consonne vérifions cette structure

```
# version initiale
case 'corse':
    if int(year) >= 2025:
        if month in ['janvier', 'mai']:
            url_haute_corse = (
                'https://www.haute-corse.gouv.fr'
                '/Publications'
                '/Publications-administratives-et-legales'
                '/Recueils-des-actes-administratifs'
                f'/Recueils-des-actes-administratifs-{year}'
                f'/RAA-du-mois-de-{month}-{year}'
            )
        elif month in ['avril', 'aout', 'octobre']:
            url_haute_corse = (
                'https://www.haute-corse.gouv.fr'
                '/Publications'
                '/Publications-administratives-et-legales'
                '/Recueils-des-actes-administratifs'
                f'/Recueils-des-actes-administratifs-{year}'
                f'/RAA-du-mois-d-{month}-{year}'
            )
        else:
            url_haute_corse = (
                'https://www.haute-corse.gouv.fr'
                '/Publications'
                '/Publications-administratives-et-legales'
                '/Recueils-des-actes-administratifs'
                f'/Recueils-des-actes-administratifs-{year}'
                f'/RAA-du-mois-{month}-{year}'
            )

# version corrigée
case 'corse':
    if int(year) >= 2025:
        if month in ['janvier', 'mai', 'juin', 'juillet', 'septembre', 'novembre', 'decembre']:
            url_haute_corse = (
                'https://www.haute-corse.gouv.fr'
                '/Publications'
                '/Publications-administratives-et-legales'
                '/Recueils-des-actes-administratifs'
                f'/Recueils-des-actes-administratifs-{year}'
                f'/RAA-du-mois-de-{month}-{year}'
            )
        elif month in ['avril', 'aout', 'octobre']:
            url_haute_corse = (
                'https://www.haute-corse.gouv.fr'
                '/Publications'
                '/Publications-administratives-et-legales'
                '/Recueils-des-actes-administratifs'
                f'/Recueils-des-actes-administratifs-{year}'
                f'/RAA-du-mois-d-{month}-{year}'
            )
        else:
            url_haute_corse = (
                'https://www.haute-corse.gouv.fr'
                '/Publications'
                '/Publications-administratives-et-legales'
                '/Recueils-des-actes-administratifs'
                f'/Recueils-des-actes-administratifs-{year}'
                f'/RAA-du-mois-{month}-{year}'
            )
```

2. Occitanie - juillet 2025

```
# extrait du cas 'occitanie' en date de juin 2025

case 'occitanie':

    if int(year) >= 2025:

        if month == 'janvier': # si le mois est égal à 'janvier' <-> équivalent à if month in ['janvier']
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                '/Recueil-des-Actes-Administratifs'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-de-{month}-{year}-en-region-{region}'
            )

        # en février, on perd '/Recueil-des-Actes-Administratifs'
        # et l'on ajoute le chiffre 2 en fin d'url
        elif month == 'fevrier':
            url = (
                f'{root}/{region}'
                '/Documents-publications/'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-de-{month}-{year}-en-region-{region}2'
            )

        # en avril on conserve la nouvelle structure inaugurée en mars
        # mais "de" est remplacé par "d"
        # -> on généralise ce principe pour tous les mois commençant par une consonne
        elif month in ['avril', 'aout', 'octobre']:
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                '/Recueil-des-Actes-Administratifs'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-d-{month}-{year}'
            )

        # en juin, on perd à nouveau '/Recueil-des-Actes-Administratifs'
        elif month in ['juin']:
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-de-{month}-{year}'
            )

        # à partir de mars (inclus dans la clause else), on récupère '/Recueil-des-Actes-Administratifs'
        # la structure de la dernière partie est modifiée :
        # f'/Recueil-des-Actes-Administratifs-R.A.A.-de-{month}-{year}-en-region-{region}'
        # est remplacée par:
        # f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-de-{month}-{year}'
        else:
            url = (
                f'{root}/{region}' # on intègre notre string dans une f-string dès lors qu'elle comporte
                # au moins une variable
                '/Documents-publications'
                '/Recueil-des-Actes-Administratifs'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-de-{month}-{year}'
            )
```

'juillet' est inclus dans la clause `else`, l'adresse renvoyée par `get_url('occitanie', 'juillet', '2025')` renverra une erreur 404 (page not found) :

```
get_url('occitanie', 'juillet', '2025')
# renvoie:
'https://www.prefectures-regions.gouv.fr/occitanie/Documents-publications/Recueil-des-Actes-Administratifs/Recueil-des-Actes-Administratifs-R.A.A.-en-region-occitanie-de-juillet-2025'
```

Récupérer la bonne adresse :

- rendez-vous sur : <https://www.prefectures-regions.gouv.fr>
- carte interactive -> cliquez sur **Occitanie** -> onglet droit **Recueil des actes administratifs** -> **Recueil des actes administratifs (R.A.A.) en région Occitanie de Juillet 2025**
- dans le champs `adresse` de votre navigateur copiez/collez cette dernière et comparez

```
# adresse incorrecte
'https://www.prefectures-regions.gouv.fr/occitanie/Documents-publications/Recueil-des-Actes-Administratifs/Recueil-des-Actes-Administratifs-R.A.A.-en-region-occitanie-de-juillet-2025'

# adresse correcte
https://www.prefectures-regions.gouv.fr/occitanie/Documents-publications/Recueil-des-actes-administratifs-R.A.A.-en-region-Occitanie-de-Juillet-2025
```

- Mettre en forme, décomposer la variable `url` et remplacer les valeurs `juillet` et `2025` par leurs variables respectives :

```
url = 'https://www.prefectures-regions.gouv.fr/occitanie/Documents-publications/Recueil-des-actes-administratifs-R.A.A.-en-region-Occitanie-de-Juillet-2025'

# équivaut à:

url = (
    'https://www.prefectures-regions.gouv.fr/occitanie'
    '/Documents-publications'
    '/Recueil-des-actes-administratifs-R.A.A.-en-region-Occitanie-de-Juillet-2025'
)

# on remplace les valeurs par leurs noms de variables respectives

url = (
    f'{root}/{region}'
    '/Documents-publications'
    f'/Recueil-des-actes-administratifs-R.A.A.-en-region-{region}-de-{month}-{year}'
)
```

On remarque que l'url de juillet a la même structure que dans notre clause initiale `elif month in ['juin']`

- Corriger le case 'occitanie' de la fonction `get_url()` :

```
# version corrigée

case 'occitanie':

    if int(year) >= 2025:

        if month == 'janvier':
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                '/Recueil-des-Actes-Administratifs'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-de-{month}-{year}-en-region-{region}'
            )

        elif month == 'fevrier':
            url = (
                f'{root}/{region}'
                '/Documents-publications/'
                f'Recueil-des-Actes-Administratifs-R.A.A.-de-{month}-{year}-en-region-{region}2'
            )

        elif month in ['mars', 'mai']:
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                '/Recueil-des-Actes-Administratifs'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-de-{month}-{year}'
            )

        elif month == 'avril':
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                '/Recueil-des-Actes-Administratifs'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-d-{month}-{year}'
            )

        elif month in ['juin', 'juillet', 'septembre', 'novembre', 'decembre']:
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-de-{month}-{year}'
            )

        elif month in ['aout', 'octobre']:
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-d-{month}-{year}'
            )
```

```
# maj août 25

case 'occitanie':

    if int(year) >= 2025:

        if month == 'janvier':
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                '/Recueil-des-Actes-Administratifs'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-de-{month}-{year}-en-region-{region}'
            )

        elif month == 'fevrier':
            url = (
                f'{root}/{region}'
                '/Documents-publications/'
                f'Recueil-des-Actes-Administratifs-R.A.A.-de-{month}-{year}-en-region-{region}2'
            )

        elif month in ['mars', 'mai']:
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                '/Recueil-des-Actes-Administratifs'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-de-{month}-{year}'
            )

        elif month in ['avril', 'aout', 'octobre']:
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                '/Recueil-des-Actes-Administratifs'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-d-{month}-{year}'
            )

        elif month in ['juin', 'juillet', 'septembre', 'novembre', 'decembre']:
            url = (
                f'{root}/{region}'
                '/Documents-publications'
                f'/Recueil-des-Actes-Administratifs-R.A.A.-en-region-{region}-de-{month}-{year}'
            )
```

3. Martinique - 2024 -> 2025

```
# Extrait du cas 'martinique', fonctionnel jusqu'en décembre 2024

case 'martinique':

    url_common = (
        f'https://www.{region}.gouv.fr'
        '/Publications'
        '/Recueils-des-actes-administratifs-publies'
        f'/RAAP-{year}'
        '/Recueil-des-Actes-Administratifs'
        f'/{month}'
    )

    url_special = (
        f'https://www.{region}.gouv.fr'
        '/Publications'
        '/Recueils-des-actes-administratifs-publies'
        f'/RAAP-{year}'
        '/Recueil-des-Actes-Administratifs-Special'
        f'/{month}'
    )

    urls = [url_common, url_special]
```

Pour le mois de janvier 2025 :

```
get_url('martinique', 'janvier', '2025')
# renvoie:
['https://www.martinique.gouv.fr/Publications/Recueils-des-actes-administratifs-publies/RAAP-2025/Recueil-des-Actes-Administratifs/janvier',
 'https://www.martinique.gouv.fr/Publications/Recueils-des-actes-administratifs-publies/RAAP-2025/Recueil-des-Actes-Administratifs-Special/janvier']
```

Les adresses renvoyées par la fonction nous renvoient une erreur 404 (page not found)

1. On récupère les adresses correctes via le site [Les services de l'Etat en région](#) :

- depuis la carte interactive -> **Martinique** -> **Publications** -> **Recueils des actes administratifs publiés** -> **RAA 2025**
- **Recueil des Actes Administratifs Spécial** -> **Janvier**
- on copie/colle l'adresse correcte :

```
# adresse correcte pour url_special
https://www.martinique.gouv.fr/Publications/Recueils-des-actes-administratifs-publies/RAA-2025/Recueil-des-Actes-Administratifs-Special/Janvier
```

- **Recueil des Actes Administratifs** -> **Janvier**
- on copie/colle l'adresse correcte :

```
# adresse correcte pour url_common
https://www.martinique.gouv.fr/Publications/Recueils-des-actes-administratifs-publies/RAA-2025/Recueil-des-Actes-Administratifs/Janvier
```


2. On décompose ces urls et on obtient :

```
# adresse correcte pour url_common
url_common = (
    'https://www.martinique.gouv.fr'
    '/Publications'
    '/Recueils-des-actes-administratifs-publies'
    '/RAA-2025'
    '/Recueil-des-Actes-Administratifs'
    '/Janvier'
)

# adresse correcte pour url_special
url_special = (
    'https://www.martinique.gouv.fr'
    '/Publications'
    '/Recueils-des-actes-administratifs-publies'
    '/RAA-2025'
    '/Recueil-des-Actes-Administratifs-Special'
    '/Janvier'
)

# en remplaçant les valeurs par leurs variables respectives:
# les urls ne respectent pas la casse ('janvier' équivaut à 'Janvier')

# adresse correcte pour url_common
url_common = (
    f'https://www.{region}.gouv.fr'
    '/Publications'
    '/Recueils-des-actes-administratifs-publies'
    f'/RAA-{year}'
    '/Recueil-des-Actes-Administratifs'
    f'/{month}'
)

# adresse correcte pour url_special
url_special = (
    f'https://www.{region}.gouv.fr'
    '/Publications'
    '/Recueils-des-actes-administratifs-publies'
    f'/RAA-{year}'
    '/Recueil-des-Actes-Administratifs-Special'
    f'/{month}'
)

# on note que la différence entre 2025 et les années antérieures tient à : "RAAP" devient "RAA"
```

3. On implémente ce nouveau cas :

- dans la partie dédiée à la Martinique nous allons définir 2 nouvelles conditions :
 - si l'année est supérieure ou égale à 2025
 - sinon

```
# version corrigée

case 'martinique':

    if int(year) >= 2025:
        url_common = (
            f'https://www.{region}.gouv.fr'
            '/Publications'
            '/Recueils-des-actes-administratifs-publies'
            f'/RAA-{year}'
            '/Recueil-des-Actes-Administratifs'
            f'/{month}'
        )
        url_special = (
            f'https://www.{region}.gouv.fr'
            '/Publications'
            '/Recueils-des-actes-administratifs-publies'
            f'/RAA-{year}'
            '/Recueil-des-Actes-Administratifs-Special'
            f'/{month}'
        )

    else:
        url_common = (
            f'https://www.{region}.gouv.fr'
            '/Publications'
            '/Recueils-des-actes-administratifs-publies'
            f'/RAAP-{year}'
            '/Recueil-des-Actes-Administratifs'
            f'/{month}'
        )
        url_special = (
            f'https://www.{region}.gouv.fr'
            '/Publications'
            '/Recueils-des-actes-administratifs-publies'
            f'/RAAP-{year}'
            '/Recueil-des-Actes-Administratifs-Special'
            f'/{month}'
        )

    urls = [url_common, url_special]
```

Dès lors,

```
get_url('martinique', 'janvier', '2025')
```

renvoie:

['https://www.martinique.gouv.fr/Publications/Recueils-des-actes-administratifs-publies/RAA-2025/Recueil-des-Actes-Administratifs/janvier',

'https://www.martinique.gouv.fr/Publications/Recueils-des-actes-administratifs-publies/RAA-2025/Recueil-des-Actes-Administratifs-Special/janvier']

II. Mettre à jour la fonction `get_titles_and_links()`

La fonction `get_titles_and_links()` retourne tous les titres et les liens d'une adresse donnée.

Elle prend en paramètres `region`, `month`, `year`, et fait appel à `get_url()` pour récupérer les adresses des pages web à scraper.

Pour scraper les titres et les liens, elle s'appuie sur les balises html des pages cibles.

Si ces dernières sont modifiées, il est nécessaire d'implémenter ces modifications dans `get_title_and_links()`.

Bourgogne Franche Comté - 2024 -> 2025

Nous étudierons ici les modifications du code html pour la Bourgogne Franche Comté lors du passage à 2025 et de ses répercussions sur la fonction.

```
# extrait de la version initiale

def get_titles_and_links(region, month, year):

    root = 'https://www.prefectures-regions.gouv.fr'

    match region:

        case 'bourgogne-franche-comte':

            url = get_url(region, month, year)
            soup = connect(url)

            if soup is None:
                return []

            items = soup.find_all(class_="link-download")
            titles = [item.find('span').text for item in items if f'{month} {year}' in
format_item(item.text)]
            links = [root + item.get('href') for item in items if f'{month} {year}' in
format_item(item.text)]

            return [[display(region), title, link] for title, link in zip(titles, links)]
```

```
get_titles_and_links('bourgogne-franche-comte', 'juillet', '2025')
# renvoie une liste de listes comprenant la région, le titre du recueil, le lien pdf,
# de l'ensemble des recueils administratifs parus en juillet 2025 dans la région concernée
[['Bourgogne-Franche-Comté',
  'RAA 109 Bourgogne-Franche-Comté du 25 juillet 2025',
  'https://www.prefectures-regions.gouv.fr/bourgogne-franche-
comte/irecontenu/telechargement/129810/955530/file/recueil-bfc-2025-109-recueil-des-actes-administratifs-
special.pdf'],
 ['Bourgogne-Franche-Comté',
  'RAA 108 Bourgogne-Franche-Comté du 23 juillet 2025',
  'https://www.prefectures-regions.gouv.fr/bourgogne-franche-
comte/irecontenu/telechargement/129724/954933/file/recueil-bfc-2025-108-recueil-des-actes-administratifs-
special.pdf'],
 ...
 ['Bourgogne-Franche-Comté',
  'RAA 108 Bourgogne-Franche-Comté du 23 juillet 2025',
  'https://www.prefectures-regions.gouv.fr/bourgogne-franche-
comte/irecontenu/telechargement/129724/954933/file/recueil-bfc-2025-108-recueil-des-actes-administratifs-
special.pdf'],
 ['Bourgogne-Franche-Comté',
  'RAA 109 Bourgogne-Franche-Comté du 25 juillet 2025',
  'https://www.prefectures-regions.gouv.fr/bourgogne-franche-
comte/irecontenu/telechargement/129810/955530/file/recueil-bfc-2025-109-recueil-des-actes-administratifs-
special.pdf']]
```

Le résultat est volontairement tronqué mais on note que chaque élément est présent 2 fois.

Pour analyser la structure html de cette page, rendez-vous à cette adresse :

```
get_url('bourgogne-franche-comte', 'juillet', '2025')
```

'https://www.prefectures-regions.gouv.fr/bourgogne-franche-comte/Documents-publications/Recueils-des-actes-administratifs/Recueils-des-actes-administratifs-bourgogne-franche-comte-2025'

On remarque que contrairement aux années précédentes, les liens des recueils sont également présents en double dans la page [Recueils des actes administratifs Bourgogne-Franche-Comté 2025](#)

1. Balises html de la page source

Instructions valides pour Microsoft Edge

- Une fois sur votre page source, faites un clic droit, puis **Inspecter**, votre écran se scinde en deux parties
- Dans le menu supérieur de la fenêtre qui affiche le code, cliquez sur l'icône **Inspecter** tout à gauche ou (Ctrl+Shift+I)
- En passant votre curseur sur votre affichage classique vous mettrez en surbrillance le code html correspondant et inversement.

Dans notre version initiale l'instruction `soup.find_all(class_="link-download")` récupère l'ensemble des liens de la page.

En inspectant la page web, on remarque qu'il est possible d'isoler la partie [Documents liés](#), cette partie est définie par la balise `<div class="panel-body">` et contient tous les éléments qui nous intéressent en un seul exemple.

2. Scraping

```
# avec:  
items = soup.find_all(class_="panel-body")  
# on récupère l'ensemble du bloc de code défini par la balise <div class="panel-body">
```

Aperçu du bloc html contenu dans la balise `<div class="panel-body">` :

```
<div class="panel-body">  
  <ul>  
    <li>  
      <a class="link-download"  
        href="/bourgogne-franche-comte/irecontenu/telechargement/123725/916628/file/recueil-bfc-2025-  
002-recueil-des-actes-administratifs.pdf"  
        target="_blank"  
        title="RAA 002 Bourgogne-Franche-Comté du 02 janvier 2025 - 03/01/2025" data-xiti-site="566505"  
        data-xiti-name="article::documents_liés::recueil-bfc-2025-002-recueil-des-actes-administratifs.pdf"  
        data-xiti-type="download"  
        data-xiti-niv2="11">  
        <span>RAA 002 Bourgogne-Franche-Comté du 02 janvier 2025</span>  
         (PDF - 19 911,20 ko)  
      </a>  
    </li>  
    <li>...</li>  
    ....  
  </ul>  
</div>
```

On souhaite récupérer l'ensemble des titres et des liens :

- Avec l'outil **Inspector**, on inspecte les différents éléments de la rubrique **Documents liés**.
- Chaque élément est défini dans une balise `<li>`, puis une balise `<a class="link-download">`, à l'intérieure de laquelle nous retrouvons les noms de fichiers et les liens.

```
# avec:
items = soup.find_all(class_="panel-body")[0].find_all(class_='link-download')
# on récupère l'ensemble du contenu défini par la balise <div class="panel-body"> puis par les balises <a
class="link-download">
```

```
# scraping des noms de fichier
# dans items, on souhaite récupérer l'ensemble des noms définis par les balises <span>

# affiche tous les noms de fichiers
for item in items:
    print(item.find('span').text)

# pour obtenir une liste comprenant tous les noms de fichier
[item.find('span').text for item in items]

# en incluant une condition pour ne retourner que les noms de fichiers qui vérifient le paramètre month
[item.find('span').text for item in items if f'{month}' in format_item(item.find('span').text)]
```

```
# scraping des liens
# dans items, on souhaite récupérer l'ensemble des liens définis par href

# affiche la valeur href pour chaque élément
for item in items:
    print(item.get('href'))

# pour obtenir le lien complet on ajoute la racine:
# root = 'https://www.prefectures-regions.gouv.fr' déjà définie en début de fonction

# pour obtenir une liste comprenant tous les liens
[root + item.get('href') for item in items]

# on applique notre condition
[root + item.get('href') for item in items if f'{month}' in format_item(item.find('span').text)]
```

3. Correction & implémentation du nouveau cas

```
case 'bourgogne-franche-comte':
    url = get_url(region, month, year)
    soup = connect(url)
    if soup is None:
        return []
    if int(year) >= 2025:
        items = soup.find_all(class_="panel-body")[0].find_all(class_="link-download")
    else:
        items = soup.find_all(class_="link-download")
    titles = [item.find('span').text for item in items if f'{month}' in
format_item(item.find('span').text)]
    links = [root + item.get('href') for item in items if f'{month}' in
format_item(item.find('span').text)]
```

III. Limitations & erreurs

- Pas d'analyse approfondie sur les régions Grand Est & Pays de la Loire :
Les recueils sont intégralement téléchargés dès lors qu'au moins un mot clé est trouvé
- Variabilité des urls : Le cas échéant adapter `get_url()`.
- Changement du balisage html : Le cas échéant adapter `get_titles_and_links()`.
- Temps de traitement : prévoir entre 5 à 20 minutes pour un tour complet des régions selon la charge du réseau.

Erreur	Cause probable	Solution
ERROR - Failed to connect to https://www.prefectures-regions.gouv.fr/<nom_region>/...	l'url est erronée	corriger l'url renvoyée par la fonction <code>get_url()</code>
ERROR - Cannot load empty file from https://www.prefectures-regions.gouv.fr/.../.pdf	le lien n'est pas valide	vérifier le lien directement à partir du site web et/ou tester le lien via la fonction <code>get_titles_and_links()</code>
ERROR - ReadTimeout encounterd while loading https://www.prefectures-regions.gouv.fr/.../.pdf	le site ne répond pas	réessayer ultérieurement
requests.exceptions.HTTPError: 403 Client Error: Forbidden for url: https://healthineers.sharepoint.com/teams/MSCBusinessDevelopment-AutorisationsARS/_api/contextInfo	l'utilisateur n'a pas les autorisations SharePoint adéquates	vérifier les accès SharePoint / vérifier que les identifiants ont été rentrés dans les variables d'environnement / vérifier vos identifiants

Auteur

Développé par Thomas H. pour Siemens Healthcare France